SUJET 09 • BIG DATA

Qualité et validation des données avec Great Expectations, Soda et Amazon Deequ

Nature	Projet de veille technologique avec expérimentation
Niveau	Master Data Science - Génie logiciel
Organisation	Travail en groupe selon les consignes de l'enseignant
Durée indicative	2 à 3 semaines

1. Contexte

Une chaîne décisionnelle ou Big Data ne produit des résultats fiables que si les données sont contrôlées. Les outils de data quality permettent d'exprimer des règles, d'automatiser les tests et de suivre les anomalies au fil des traitements.

2. Problématique

> Question centrale : Quel outil permet d'intégrer le plus efficacement des contrôles de qualité automatisés dans un pipeline de données ?

3. Objectifs pédagogiques

- Définir les principales dimensions de la qualité des données.
- Comparer les approches proposées par les trois outils.
- Créer une suite de règles de validation reproductibles.
- Intégrer les contrôles dans un pipeline automatisé.
- Évaluer la lisibilité des rapports et la maintenance des règles.

4. Outils et environnement suggérés

- Great Expectations
- Soda
- Amazon Deequ
- Python ou Apache Spark
- jeu de données comportant des anomalies

Les étudiants peuvent proposer un outil équivalent, sous réserve de justifier ce choix et de conserver une comparaison équitable.

5. Travail demandé

A. Étude de veille

Réaliser une recherche structurée en privilégiant les documentations officielles, les articles scientifiques, les dépôts de code officiels et les retours d'expérience techniques récents. L'étude doit couvrir les points suivants :

- Types de règles, profilage et génération de tests.
- Intégration avec fichiers, bases de données et moteurs distribués.
- Rapports, alertes et historisation des résultats.
- Intégration CI/CD et orchestration des contrôles.
- Licences, déploiement, extensibilité et facilité de prise en main.

B. Expérimentation pratique obligatoire

- Préparer un jeu d'au moins 50 000 lignes contenant des erreurs contrôlées.
- Définir au moins 12 règles couvrant complétude, unicité, validité et cohérence.
- Implémenter les mêmes contrôles avec au moins deux outils.
- Comparer la détection, le temps d'exécution et la qualité des rapports.
- Bloquer ou isoler automatiquement les données non conformes.

C. Méthode de comparaison

Construire une grille comportant des critères mesurables. Chaque critère doit être défini, pondéré et associé à une méthode de test. Les affirmations importantes doivent être appuyées par une preuve : mesure, capture, résultat reproductible ou source fiable.

Critères minimaux	Éléments attendus
Fonctionnalités	Couverture du besoin, limites et cas non pris en charge
Technique	Architecture, installation, intégration et performances
Exploitation	Sécurité, supervision, maintenance et passage à l'échelle
Écosystème	Licence, documentation, communauté et pérennité
Décision	Recommandation selon au moins deux scénarios d'usage

6. Questions directrices

- Quel outil permet d'exprimer les règles le plus clairement ?
- Les anomalies injectées sont-elles toutes détectées ?
- Comment gérer les faux positifs et l'évolution des règles ?
- Quel outil s'intègre le mieux à un pipeline industriel ?

7. Livrables obligatoires

- Rapport de veille de 10 à 15 pages.
- Jeu de données documenté et règles de validation.
- Pipeline de contrôle et rapports d'anomalies.
- Présentation de 10 à 15 diapositives.
- Vidéo de démonstration de 5 à 8 minutes.

8. Structure conseillée du rapport

- Introduction, contexte et problématique.
- Méthodologie de veille et critères de sélection des sources.
- Présentation des outils et comparaison fonctionnelle.
- Protocole expérimental, environnement et données utilisées.
- Résultats, analyse critique et limites de l'étude.
- Recommandations, conclusion et perspectives.
- Bibliographie, annexes techniques et lien vers le code source.

9. Barème d'évaluation

Élément évalué	Points
Qualité et actualité de la veille	**20**
Compréhension technique et analyse comparative	**20**
Qualité de l'expérimentation et reproductibilité	**25**
Analyse des résultats et pertinence des recommandations	**15**
Qualité du rapport et citation des sources	**10**
Présentation orale et vidéo de démonstration	**10**
TOTAL	**100**

10. Sources de départ

- Documentation Great Expectations
- Documentation Soda
- Documentation Amazon Deequ

> Important : une veille technologique ne consiste pas à recopier des descriptions d'outils. Le groupe doit vérifier les informations, expérimenter les solutions, présenter des mesures et défendre une recommandation argumentée.

Date de remise : _____ Enseignant : _____